ORUNTU TANIMA

DERS NOTLARI

Bolum 1: Oruntu Tanima Nedir?

2024-2025 Akademik Yili

1. Oruntu Tanima Nedir?

1.1 Tanim ve Temel Kavramlar

Oruntu tanima (Pattern Recognition), veri icerisindeki duzenlilikleri, kaliplari ve yapilari otomatik olarak belirleme ve siniflandirma islemine verilen isimdir. Insanlar gunluk hayatlarinda surekli oruntu tanima yaparlar: bir yuzu tanima, bir sesi ayirt etme, el yazisini okuma gibi islemler hep oruntu tanimaya dayanir.

Bilgisayar biliminde oruntu tanima, makine ogrenimi ve yapay zekanin temel konularindan birini olusturur. Amac, bir bilgisayarin verilerdeki oruntuleri otomatik olarak ogrenip, yeni veriler uzerinde dogru tahminler yapabilmesidir.

Oruntu Tanima Resmi Tanimi

Oruntu tanima, bir girdi verisinin (ornegin goruntu, ses, metin) belirli kategorilerden birine otomatik olarak atanmasi islemidir. Bu islem, veriden anlamli ozelliklerin (feature) cikarilmasi ve bu ozelliklere dayali olarak bir karar verilmesi asamalarindan olusur.

Ornek 1.1 - Gunluk Hayatta Oruntu Tanima

Bir postacinin mektuplari dagitrken el yazisi adreslerini okumasi bir oruntu tanima islemidir. Postaci:

1) Veri Toplama: Zarfin uzerindeki el yazisini gorur.

2) On Isleme: Yazinin egikligini, boyutunu zihninde normalize eder.

3) Ozellik Cikarimi: Harflerin seklini, birlesim noktalarini, egrileri analiz eder.

4) Siniflandirma: Her harfi tanir ve kelimeyi olusturur.

5) Karar: Adresi belirler ve mektubu dogru kutuya atar.

Bir bilgisayar sistemi de ayni adimlari takip eder, fakat matematiksel islemlerle yapar!

1.2 Oruntu Tanima Sistemi Bilesenleri

Tipik bir oruntu tanima sistemi asagidaki temel bilesenlerden olusur:

- **Veri Toplama (Data Acquisition):** Ham verilerin sensorler, kameralar veya diger araclarla toplanmasi asamasidir.
- **On Isleme (Preprocessing):** Toplanan ham verinin temizlenmesi, normalize edilmesi ve analiz icin uygun hale getirilmesi islemidir.

- **Ozellik Cikarimi (Feature Extraction):** Veriden anlamli ve ayirt edici ozelliklerin cikarilmasidir.
- **Ozellik Secimi (Feature Selection):** Cikarilan ozellikler arasinda en ayirt edici olanlarin secilmesidir.
- **Siniflandirma (Classification):** Ozelliklere dayali olarak verinin hangi sinifa ait olduguna karar verilmesi islemidir.
- **Karar Verme (Decision Making):** Siniflandirici ciktisinin degerlendirilmesi ve nihai kararin verilmesi asamasidir.

✍ Ornek 1.2 - Meyve Siniflandirma Sistemi

Bir fabrikada elmalar ve portakallar otomatik olarak ayrilmak isteniyor. Sistem su sekilde calisir:

Veri Toplama: Bant uzerindeki her meyvenin kamera ile goruntusu ve tartidan agirligi alinir.

On Isleme: Goruntu parlaklik normalizasyonundan gecirilir, arka plan cikarilir.

Ozellik Cikarimi: Her meyve icin su ozellikler cikarilir:

x1 = Agirlik (gram) | x2 = Cap (cm) | x3 = Kirmizi renk yogunlugu (0-255)

Ornek veri tablosu:

Meyve A: x = [180g, 7.5cm, 200] --> Elma

Meyve B: x = [220g, 8.2cm, 30] --> Portakal

Meyve C: x = [165g, 7.0cm, 185] --> Elma

Meyve D: x = [250g, 9.0cm, 25] --> Portakal

Siniflandirma: Yeni bir meyve geldiginde (ornegin x = [190g, 7.8cm, 190]), sistem bu ozellik vektorunu egitim verisiyle karsilastirir.

Karar: Kirmizi renk yogunlugu yuksek (190) ve cap kucuk (7.8cm) --> ELMA olarak siniflandirilir.

1.3 Oruntu Tanima Yaklasim Turleri

1.3.1 Istatistiksel (Statistical) Yaklasim

Istatistiksel yaklasimda, oruntuler ozellik vektorleri ile temsil edilir ve siniflandirma olasilik teorisi ve istatistiksel karar kurallarina dayanir. Bayes siniflandirici, bu yaklasimlarin en temel orneklerinden biridir.

✍ Ornek 1.3 - Istatistiksel Yaklasim: E-posta Spam Filtresi

Diyelim ki bir e-posta spam filtresi tasarliyoruz. Elimizde su istatistikler var:

Toplam e-posta sayisi: 1000
Spam e-posta sayisi: 400 --> P(Spam) = 400/1000 = 0.40
Normal e-posta sayisi: 600 --> P(Normal) = 600/1000 = 0.60

"Kazandiniz" kelimesinin gecme olasiliklari:
Spam e-postalarda: 320/400 = 0.80 --> P("Kazandiniz" | Spam) = 0.80
Normal e-postalarda: 12/600 = 0.02 --> P("Kazandiniz" | Normal) = 0.02

Soru: Yeni gelen bir e-postada "Kazandiniz" kelimesi geciyorsa, bu e-posta spam midir?

Cozum (Bayes Kurali):
P(Spam | "Kazandiniz") = P("Kazandiniz" | Spam) * P(Spam) / P("Kazandiniz")
P("Kazandiniz") = 0.80 * 0.40 + 0.02 * 0.60 = 0.32 + 0.012 = 0.332
P(Spam | "Kazandiniz") = (0.80 * 0.40) / 0.332 = 0.32 / 0.332 = 0.964

Sonuc: %96.4 olasilikla bu e-posta SPAM'dir!

1.3.2 Yapisal (Structural) Yaklasim

Yapisal yaklasimda, oruntuler alt bilesenleri ve bu bilesenlerin iliskileri ile tanimlanir. Gramer temelli yontemler ve grafik eslestirme teknikleri bu kategoriye girer.

✍ Ornek 1.4 - Yapisal Yaklasim: Plaka Tanima

Bir otopark girisinde plaka tanima sistemi yapisal yaklasim kullanir:

Plaka yapisi: [2 harf] [Bosluk] [4 rakam] [Bosluk] [2-3 harf]
Ornek: 05 ABC 1234

Sistem su yapisal kurallari uygular:

1. Ilk 2 karakter: Sayi (il kodu) --> 01-81 araliginda olmali
2. Ortadaki karakterler: Harf (1-3 adet) --> Turkce alfabe harfleri
3. Son karakterler: Sayi (2-4 adet)

Eger bir karakter grubu bu kurallara uymazsa, sistem hatali okuma yaptigini anlar ve yeniden dener.

Ornegin: "O5 A8C 1234" okundugunda, "8" harfler arasinda olamayacagi icin sistem bunu "B" olarak duzeltir.

1.3.3 Makine Ogrenimi (Machine Learning) Yaklasimi

Makine ogrenimi yaklasiminda, sistem dogrudan verilerden ogrenme yoluyla oruntuler kesfeder. Sinir aglari, karar agaclari, destek vektor makineleri (SVM) gibi algoritmalar bu yaklasimin temel araclaridir.

✍ Ornek 1.5 - Makine Ogrenimi: El Yazisi Rakam Tanima (MNIST)

MNIST veri seti, makine ogreniminde en klasik orneklerden biridir:

Veri seti: 70.000 el yazisi rakam goruntusu (0-9)
Egitim seti: 60.000 goruntu
Test seti: 10.000 goruntu
Goruntu boyutu: 28 x 28 piksel = 784 ozellik

Her goruntu 784 boyutlu bir ozellik vektoru olarak temsil edilir:
x = [piksel_1, piksel_2, ..., piksel_784] her piksel 0-255 arasi

Farkli algoritmalarin bu veri setindeki basarimlari:
k-NN (k=3): %97.2 dogruluk
SVM (RBF kernel): %98.5 dogruluk
Random Forest: %96.8 dogruluk
Derin Sinir Agi (CNN): %99.7 dogruluk

Goruldugu gibi, derin ogrenme modelleri en yuksek basarimi saglarken, basit yontemler bile oldukca iyi sonuclar verebilmektedir.

1.3.4 Sablona Dayali (Template-based) Yaklasim

Bu yaklasimda, girdi verisi onceden tanimlanmis sablonlarla karsilastirilir. En basit oruntu tanima yontemlerinden biridir.

✍ Ornek 1.6 - Sablon Eslestirme: QR Kod Okuyucu

QR kod okuyucu uygulamasi sablon eslestirme kullanir:

1. Once goruntuede QR kodun 3 kosesindeki kare sablon bulunur (finder pattern)
2. Bu sablonlar her zaman ayni boyut oranina sahiptir: siyah:beyaz:siyah:beyaz:siyah = 1:1:3:1:1
3. Sistem goruntuyu tararak bu orana uyan bolgeleri arar
4. 3 finder pattern bulununca QR kodun sinilari belirlenir

Bu yaklasim hizlidir ancak sablonda bozulma varsa (ornegin QR kod burusmus kagittaysa) basarisiz olabilir.

Yaklasimlarin Karsilastirmasi

Yaklasim	Avantaj	Dezavantaj	Ornek Uygulama
Istatistiksel	Matematiksel temeli guclu, belirsizlik olcumu yapar	Olasilik dagilimi varsayimi gerektirir	Spam filtre, tibbi teshis
Yapisal	Karmasik iliskileri modelleyebilir	Kural olusturmak zor, esnek degil	Plaka tanima, kimyasal formul
Makine Ogrenimi	Veriden otomatik ogrenir, esnek	Cok veri gerektirir, kara kutu	Goruntu tanima, NLP
Sablon Dayali	Basit, anlasilir, hizli	Varyasyonlara dayanaksiz	QR kod, barkod okuma

1.4 Ogrenme Turleri

Ogrenme Turu	Aciklama	Ornek
Gozetimli (Supervised)	Her egitim orneginin sinif etiketi bilinir. Model girdi-cikti iliskisini ogrenir.	E-posta: spam/normal etiketi verilmis 10.000 e-posta ile egitim
Goetimsiz (Unsupervised)	Sinif etiketleri yoktur. Model verinin dogal yapisini kesfeder.	Musteri segmentasyonu: musterileri alisveris davranisinara gore kume
Yari Gozetimli (Semi-supervised)	Az etiketli + cok etiketsiz veri birlikte kullanilir.	100 etiketli + 10.000 etiketsiz goruntu ile egitim
Pekistirmeli (Reinforcement)	Agent odul/ceza ile ogrenir.	AlphaGo: Her hamle sonrasi kazanma olasiligina gore odul

✍ Ornek 1.7 - Gozetimli vs Goetimsiz Ogrenme Farki

Senaryo: Bir universite 1000 ogrencisinin verilerini analiz etmek istiyor.

Gozetimli Ogrenme Ornegi:

Amac: Ogrencinin dersten gecip gecemeyecegini tahmin etmek

Girdi ozellikleri: x = [devam_orani, odev_ortalamasi, vize_notu]

Cikti etiketi: y = {Gecti, Kaldi}

Egitim: Gecmis yillarin verileri kullanilir (etiketler biliniyor)

Tahmin: Yeni ogrenci icin x = [0.85, 72, 65] --> Gecti (%78 olasilik)

Goetimsiz Ogrenme Ornegi:

Amac: Ogrencileri calisma aliskanliklarina gore gruplamak

Girdi ozellikleri: x = [gunluk_calisma_saati, kutuphane_ziyaret, online_kaynak_kullanimi]

Etiket YOK - sistem kendisi 3 kume bulur:

Kume 1: "Yogun calisan" - yuksek saat, sik kutuphane, cok kaynak

Kume 2: "Orta calisan" - orta duzey tum ozellikler

Kume 3: "Az calisan" - dusuk tum degerler

1.5 Ozellik Uzayi ve Sinif Sinirlari

Oruntu tanimada her veri noktasi bir ozellik vektoru olarak temsil edilir. N tane ozelligi olan bir veri noktasi, N boyutlu ozellik uzayinda bir nokta olarak dusunulebilir.

Ozellik Vektoru: Bir veri ornegini tanimlayan sayisal degerler kumesidir.

Sinif Siniri (Decision Boundary): Ozellik uzayinda farkli siniflari birbirinden ayiran sinir veya yuzeydir.

✍ Ornek 1.8 - Ozellik Uzayinda Siniflandirma (Sayisal)

Diyelim ki hastalik teshisi icin 2 ozellik kullaniyoruz:

x1 = Vucut sicakligi (C)

x2 = Beyaz kan hucresi sayisi (bin/uL)

Egitim verimiz:

Hasta 1: [37.0, 6.5] --> Saglikli

Hasta 2: [36.8, 7.0] --> Saglikli
Hasta 3: [38.5, 12.0] --> Hasta
Hasta 4: [39.2, 15.0] --> Hasta
Hasta 5: [37.2, 5.8] --> Saglikli
Hasta 6: [38.8, 13.5] --> Hasta

Bu verileri 2 boyutlu bir grafige cizsek:
- Saglikli hastalar sol alt bolgede kume olusturur (dusuk sicaklik, dusuk WBC)
- Hasta bireyler sag ust bolgede kume olusturur (yuksek sicaklik, yuksek WBC)

Basit bir karar siniri olusturabiliriz:
EGER x1 > 38.0 VE x2 > 10.0 ISE --> HASTA
DEGIL ISE --> SAGLIKLI

Yeni hasta: [38.3, 11.5] --> x1=38.3 > 38.0 VE x2=11.5 > 10.0 --> HASTA
Yeni hasta: [37.1, 8.0] --> x1=37.1 < 38.0 --> SAGLIKLI

⚠ **Boyut Laneti (Curse of Dimensionality)**
Ozellik sayisi arttikca ozellik uzayi ustel olarak buyur ve veriler cok seyrek hale gelir.

Ornek:
1 boyutta: [0,1] araligini 10 parca bolmek icin 10 nokta yeter
2 boyutta: [0,1] x [0,1] alanini kaplamak icin 10 x 10 = 100 nokta gerekir
3 boyutta: 10 x 10 x 10 = 1.000 nokta gerekir
10 boyutta: 10^10 = 10 milyar nokta gerekir!
100 boyutta: 10^100 nokta gerekir (evrendeki atom sayisindan fazla!)

Bu nedenle ozellik secimi ve boyut indirgeme (PCA gibi) kritik oneme sahiptir.

1.6 Oruntu Tanima Uygulama Alanlari

Bilgisayarli Goru (Computer Vision)

- Yuz tanima ve yuz dogrulama sistemleri
- Otonom arac surme (nesne tespiti, serit takibi)

- Tibbi goruntu analizi (rontgen, MR, tomografi)
- Optik karakter tanima (OCR)

✍ Ornek 1.9 - Tibbi Goruntu Analizi

Bir gogus rontgeninde akciager nodulu tespit sistemi:

Girdi: 2048 x 2048 piksel rontgen goruntusu
Ozellikler: Yogunluk desenleri, kenar bilgileri, doku ozellikleri
Cikti: Nodul var / Nodul yok + Konum bilgisi

Gercek dunyada basarimlar:
- Derin ogrenme modelleri: %94 duyarlilik (sensitivity)
- Uzman radyolog: %87 duyarlilik
- Model + Radyolog birlikte: %97 duyarlilik

Not: Bu, yapay zekanin doktoru degistirmedigini, destekledigini gosterir.

Dogal Dil Isleme (NLP)

- Metin siniflandirma ve duygu analizi
- Spam tespiti
- Otomatik ceviri
- Soru-cevap sistemleri

Ses ve Konusma

- Konusma tanima (speech recognition)
- Konusmaci kimliklendirme
- Muzik tur siniflandirma

Biyometri

- Parmak izi tanima
- Iris tanima
- Yuruyus analizi (gait recognition)

✍ Ornek 1.10 - Parmak Izi Tanima Sistemi

Bir telefonun parmak izi sensoru su adimlari izler:

1. Sensor parmak izini 500 DPI cozunurlukle tarar
2. On isleme: Kontrast iyilestirme, gurultu giderme
3. Ozellik cikarimi: Minutiae noktalari (dal ayrimlar, son noktalar)
   - Tipik bir parmak izinde 40-100 minutiae noktasi bulunur
   - Her nokta: (x, y, aci) bilgisi tasir
4. Eslestirme: Kayitli sablonla karsilastirilir
   - Eger 12+ minutiae noktasi eslesirse --> ESLESTI
   - FBI standardi: minimum 12 minutiae eslesmesi gerektirir

Hata oranlari:
FAR (False Accept Rate): %0.001 (100.000'de 1 yanlis kabul)
FRR (False Reject Rate): %0.1 (1.000'de 1 yanlis red)

1.7 Performans Degerlendirmesi

Bir oruntu tanima sisteminin ne kadar iyi calistigini degerlendirmek icin cesitli metrikler kullanilir.

Karisiklik Matrisi (Confusion Matrix)

Siniflandirma sonuclarini ozetleyen en temel aractir:

	Tahmin: Pozitif	Tahmin: Negatif
Gercek: Pozitif	True Positive (TP)	False Negative (FN)
Gercek: Negatif	False Positive (FP)	True Negative (TN)

Ornek 1.11 - Performans Metrikleri Hesaplama (Sayisal)

Bir COVID-19 test sistemi 200 kisi uzerinde degerlendirildi:

Gercekte hasta olan: 50 kisi
Gercekte saglikli olan: 150 kisi

Test sonuclari:
TP = 45 (hasta ve dogru tespit)
FN = 5 (hasta ama test negatif - KACIRILAN HASTALAR)

FP = 10 (saglikli ama test pozitif - YANLIS ALARM)

TN = 140 (saglikli ve dogru tespit)

Accuracy = (45 + 140) / 200 = 185/200 = %92.5

Precision = 45 / (45 + 10) = 45/55 = %81.8

"Pozitif cikan sonuclarin ne kadari gercekten hasta?"

Recall = 45 / (45 + 5) = 45/50 = %90.0

"Gercek hastalarin ne kadari yakalandi?"

F1 Skoru = 2 * (0.818 * 0.90) / (0.818 + 0.90) = 1.4724 / 1.718 = %85.7

Yorum: Recall (%90) cok onemli cunku 5 hasta kaciriliyor! Tibbi testlerde recall, precision'dan daha kritiktir cunku hasta birinin kacirilmasi, saglikli birinin tekrar test edilmesinden cok daha tehlikelidir.

Performans Metrikleri Ozet Tablosu

Metrik	Formul	Ne Zaman Onemli?
Accuracy	(TP+TN) / (TP+TN+FP+FN)	Siniflar dengeli oldugunda genel basarim olcusu
Precision	TP / (TP+FP)	Yanlis alarm maliyetli oldugunda (spam filtresi)
Recall	TP / (TP+FN)	Kacirma maliyetli oldugunda (kanser teshisi)
F1 Skoru	2*(P*R)/(P+R)	Precision ve Recall dengesi gerektiginde

⚠ Accuracy Paradoksu - Dikkat!

Accuracy yaniltici olabilir! Diyelim ki 10.000 kisiden sadece 100'u hasta.

Eger model HERKESE "saglikli" derse:

TP = 0, FN = 100, FP = 0, TN = 9900

Accuracy = 9900/10000 = %99.0 --> Cok yuksek gorunuyor!

Ama Recall = 0/100 = %0 --> Hicbir hasta yakalanmamis!

Bu yuzden dengesiz sinif dagilimlarinda accuracy tek basina YETERSIZ bir metriktir.

F1 skoru veya ROC-AUC gibi metrikler tercih edilmelidir.

1.8 Capraz Dogrulama ve Model Degerlendirme

k-Katli Capraz Dogrulama (k-Fold Cross-Validation)

Modelin gercek performansini olcmek icin veri k esit parcaya bolunur. Her adimda bir parca test, geri kalan k-1 parca egitim icin kullanilir.

✍ Ornek 1.12 - 5-Katli Capraz Dogrulama

Elimizde 1000 veri noktasi var, 5-katli capraz dogrulama uyguluyoruz:

```
Kat 1: Test=[1-200],     Egitim=[201-1000]   --> Dogruluk: %88
Kat 2: Test=[201-400],   Egitim=[1-200,401-1000]  --> Dogruluk: %91
Kat 3: Test=[401-600],   Egitim=[1-400,601-1000]  --> Dogruluk: %87
Kat 4: Test=[601-800],   Egitim=[1-600,801-1000]  --> Dogruluk: %90
Kat 5: Test=[801-1000],  Egitim=[1-800]     --> Dogruluk: %89
```

Ortalama Dogruluk: (88+91+87+90+89) / 5 = %89.0

Standart Sapma: ~1.58 (dusuk sapma = kararli model)

Bu yontem, tek bir train/test ayirmasina gore cok daha guvenilir sonuc verir cunku modelin performansi tum verinin farkli parcalari uzerinde test edilmistir.

1.9 Asiri Ogrenme ve Yetersiz Ogrenme

Overfitting (Asiri Ogrenme)

Model egitim verisini cok iyi ogrenir ancak yeni verilere genelleyemez. Model, verideki gurultuyu bile ezberlememistir.

✍ Ornek 1.13 - Overfitting Senaryosu

Bir ogrenci sinav sorularini ezberlerse ama konuyu anlamazsa overfitting yapmis olur!

Matematiksel ornek - Polinom uydurma:

5 veri noktamiz var: (1,2), (2,4), (3,5), (4,4), (5,6)

Model 1 (Dogrusal - Underfitting): $y = 1.2x + 1.0$

Egitim hatasi: 1.36 | Test hatasi: 1.42 (ikisi de yuksek)

Model 2 (2. derece polinom - Uygun): $y = -0.3x^2 + 2.5x - 0.2$

Egitim hatasi: 0.32 | Test hatasi: 0.45 (ikisi de makul)

Model 3 (4. derece polinom - Overfitting): $y = 0.1x^4 - 1.5x^3 + ...$

Egitim hatasi: 0.00 | Test hatasi: 8.75 (egitim mukemmel, test felaket!)

Model 3, 5 noktadan tam gecen bir egridir ama noktalar arasinda cildirca sallanir!

Underfitting (Yetersiz Ogrenme)

Model, verideki temel oruntuleri bile ogrenememistir. Hem egitim hem test dogrulugu dusuktur.

Overfitting Onleme Yontemleri

- **Daha fazla egitim verisi toplamak:** En etkili yontem. Veri arttikca model gurultu yerine gercek oruntuleri ogrenir.
- **Regularizasyon (Duzenlestirme):** Modelin karmasikligina ceza ekler. L1 (Lasso) ve L2 (Ridge) regularizasyon en yaygin yontemlerdir.
- **Capraz dogrulama:** Modelin gercek performansini olcmeye yardimci olur.
- **Erken durdurma (Early stopping):** Validation hatasinin artmaya basladigi noktada egitimi durdurur.
- **Dropout:** Sinir aglarinda rastgele noronlari devre disi birakir.
- **Ozellik secimi / boyut indirgeme:** Gereksiz ozellikleri cikartir.

Bias-Variance Dengesi

Iyi bir model, bias (yanilgi) ve variance (degiskenlik) arasinda dengelidir:

Yuksek Bias + Dusuk Variance = Underfitting (basit model, tutarli ama yanlis)

Dusuk Bias + Yuksek Variance = Overfitting (karmasik model, egitimde iyi ama tutarsiz)

Dengeli Bias + Variance = Ideal model (genelleme yapabilen)

Benzetme: Dart tahtasinda:

Yuksek bias = tum oklar tahtanin bir kosesinde (tutarli ama isabetsiz)

Yuksek variance = oklar her yere dagilmis (isabetsiz ve tutarsiz)

Ideal = tum oklar hedefin merkezinde (isabetli ve tutarli)

1.10 Oruntu Tanima Tarihcesi

Donem	Gelisme	Etki
1950'ler	Rosenblatt'in Perceptron modeli	Ilk yapay sinir agi, dogrusal siniflandirma
1960'lar	Bayes karar teorisi, en yakin komsu yontemleri	Istatistiksel oruntu tanima temelleri
1970'ler	Dinamik programlama, gizli Markov modelleri	Konusma tanima uygulamalari
1980'ler	Backpropagation algoritmasi	Cok katmanli sinir aglarinin egitimi
1990'lar	SVM, kernel yontemleri, Random Forest	Guclu siniflandiricilar, kucuk veri ile iyi basarim
2010'lar	Derin ogrenme, CNN, RNN, GAN	Goruntu, ses, dil islemede insan seviyesi basarim
2020'ler	Transformer, GPT, BERT, difuzyon modelleri	Buyuk dil modelleri, uretici yapay zeka

1.11 Bolum Ozeti

Kavram	Ozet
Oruntu Tanima	Verideki duzenlilikleri otomatik olarak belirleme ve siniflandirma
Sistem Bilesenleri	Veri toplama > On isleme > Ozellik cikarimi > Secim > Siniflandirma > Karar
Yaklasimlar	Istatistiksel, yapisal, makine ogrenimi, sablona dayali
Ogrenme Turleri	Gozetimli, goetimsiz, yari gozetimli, pekistirmeli
Ozellik Uzayi	Her veri noktasi N boyutlu uzayda bir vektordur
Degerlendirme	Accuracy, precision, recall, F1 skoru, capraz dogrulama
Zorluklar	Overfitting, underfitting, bias-variance dengesi, boyut laneti

1.12 Calisma Sorulari

1. Oruntu tanima sisteminin temel bilesenlerini siralayiniz ve her birini bir MEYVE SINIFLANDIRMA ornegi uzerinden aciklayiniz.
2. Bir bankanin kredi basvuru degerlendirme sistemi hangi tur ogrenme kullanir? Ozellikleri neler olabilir? Aciklayiniz.
3. Asagidaki confusion matrix icin accuracy, precision, recall ve F1 skorunu hesaplayiniz: TP=80, FP=15, FN=20, TN=185

4. Bir kanser teshis sisteminde precision mi yoksa recall mi daha onemlidir? Neden? Sayisal bir ornekle aciklayiniz.
5. Overfitting nedir? Bir ogrencinin sinav hazirligi uzerinden benzetme yaparak aciklayiniz. Overfitting'i onlemek icin 3 yontem yaziniz.
6. 10.000 alisveris verisi var ve sadece 50 tanesi dolandiricilik. Model herkese "normal" derse accuracy nedir? Bu neden yanilticidir? Hangi metrik daha uygun olur?
7. Boyut laneti (Curse of Dimensionality) kavramini aciklayiniz. 5 boyutlu bir uzayda, her boyutu 10 parcaya bolmek istersek kac veri noktasina ihtiyac duyulur?
8. Istatistiksel, yapisal, makine ogrenimi ve sablon tabanli yaklasimlari avantaj ve dezavantajlariyla karsilastiran bir tablo olusturunuz.
9. 5-katli capraz dogrulamada toplam 500 veri varsa, her katta kac veri egitim, kac veri test icin kullanilir? Bu yontemin avantajini aciklayiniz.
10. Bir e-postada "Tebrikler", "Ucretsiz" ve "Hemen" kelimeleri geciyorsa, verilen olasilik degerlerini kullanarak Bayes kurali ile spam olasiligini hesaplayiniz: P(Spam)=0.3, P(kelime|Spam)=0.7, P(kelime|Normal)=0.05