ORUNTU TANIMA

DERS NOTLARI

Bolum 2: Olasiliga Giris ve Bayes Kurali

2024-2025 Akademik Yili

2. Olasiliga Giris ve Bayes Kurali

2.1 Olasilik Nedir?

Olasilik, bir olayin gerceklesme ihtimalinin sayisal olarak ifade edilmesidir. Oruntu tanima sistemleri belirsizlik altinda karar vermek zorundadir ve bu kararlar olasilik teorisine dayanir. Bir siniflandirici, "bu goruntu %92 olasilikla kedi, %8 olasilikla kopektir" gibi olasiliksal ciktilar uretir.

Olasilik Aksiyomlari (Kolmogorov)

1. Her olay icin: $0 \leq P(A) \leq 1$
2. Kesin olayin olasiligi: $P(S) = 1$ (S = ornek uzay)
3. Ayrik olaylar icin: $P(A \cup B) = P(A) + P(B)$ (eger $A \cap B = \emptyset$ ise)

Temel Olasilik Kavramlari

Deney (Experiment): Sonucu onceden kesin olarak bilinmeyen islem. Ornegin zar atma, madeni para atma.

Ornek Uzay (Sample Space, S): Bir deneyin tum olasi sonuclarinin kumesi. Ornegin zar icin $S = \{1, 2, 3, 4, 5, 6\}$.

Olay (Event, A): Ornek uzayin bir alt kumesi. Ornegin "cift sayi gelme" olayi $A = \{2, 4, 6\}$.

Ornek 2.1 - Temel Olasilik Hesabi: Zar Atma

Bir zar atiliyor. Ornek uzay $S = \{1, 2, 3, 4, 5, 6\}$

Soru 1: Cift sayi gelme olasiligi nedir?

$A = \{2, 4, 6\}$ --> $P(A) = |A| / |S| = 3/6 = 0.50$

Soru 2: 3'ten buyuk sayi gelme olasiligi nedir?

$B = \{4, 5, 6\}$ --> $P(B) = 3/6 = 0.50$

Soru 3: Cift VE 3'ten buyuk sayi gelme olasiligi nedir?

$A \cap B = \{4, 6\}$ --> $P(A \cap B) = 2/6 = 0.333$

Soru 4: Cift VEYA 3'ten buyuk sayi gelme olasiligi nedir?

$P(A \cup B) = P(A) + P(B) - P(A \cap B) = 0.50 + 0.50 - 0.333 = 0.667$

Dogrulama: $A \cup B = \{2, 4, 5, 6\}$ --> $4/6 = 0.667$ ✓

Ornek 2.2 - Oruntu Tanima Baglami: Siniflandirma Olasiliklari

Bir e-posta siniflandirma sistemi 10.000 e-posta uzerinde test ediliyor:

Toplam e-posta: 10.000

Spam: 3.000 Normal: 7.000

Rastgele bir e-posta sectigimizde:

$P(\text{Spam}) = 3.000 / 10.000 = 0.30$

$P(\text{Normal}) = 7.000 / 10.000 = 0.70$

$P(\text{Spam}) + P(\text{Normal}) = 0.30 + 0.70 = 1.00$ ✓

Bu degerlere "oncel olasilik" (prior probability) denir. Herhangi bir bilgi olmadan, rastgele secilen bir e-postanin spam olma olasiligi %30'dur.

2.2 Kosullu Olasilik (Conditional Probability)

Kosullu olasilik, bir olay hakkinda baska bir olayin gerceklestigi bilindiginde hesaplanan olasilidir. Oruntu tanima icin son derece onemlidir cunku siniflandirma kararlari kosullu olasiliklara dayanir.

Kosullu Olasilik Formulu

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}$$

Okunusu: "B oldugu bilindiginde A'nin olasiligi"

Kosul: $P(B) > 0$ olmalidir.

Ornek 2.3 - Kosullu Olasilik: Kart Cekme

52 kartlik standart desteden bir kart cekildi.

Soru: Kartin kirmizi oldugu biliniyorsa, kupa olmasi olasiligi nedir?

A = Kupa olmasi
B = Kirmizi olmasi

P(B) = 26/52 = 0.50 (26 kirmizi kart: 13 kupa + 13 karo)
P(A ∩ B) = 13/52 = 0.25 (13 kupa karti hem kupa hem kirmizi)

P(A | B) = P(A ∩ B) / P(B) = 0.25 / 0.50 = 0.50

Yorum: Kartin kirmizi oldugunu bilmek, kupa olma olasiligini %25'ten %50'ye yukseltir!

✍ Ornek 2.4 - Kosullu Olasilik: Tibbi Test

Bir sehirde 100.000 kisi yasiyor. Bir hastalik prevalansi %1.

Hasta sayisi: 1.000
Saglikli sayisi: 99.000

Test ozellikleri:
Duyarlilik (Sensitivity): %99 --> P(Test+ | Hasta) = 0.99
Ozgulluk (Specificity): %95 --> P(Test- | Saglikli) = 0.95

Test sonuclari:
Hasta ve Test+: 1.000 x 0.99 = 990 kisi (True Positive)
Hasta ve Test-: 1.000 x 0.01 = 10 kisi (False Negative)
Saglikli ve Test+: 99.000 x 0.05 = 4.950 kisi (False Positive)
Saglikli ve Test-: 99.000 x 0.95 = 94.050 kisi (True Negative)

Soru: Testi pozitif cikan birinin GERCEKTEN hasta olma olasiligi nedir?

P(Hasta | Test+) = 990 / (990 + 4.950) = 990 / 5.940 = 0.1667

Sonuc: Testi pozitif cikan birinin gercekten hasta olma olasiligi sadece %16.7!

Bu sasirtici sonuc, dusuk prevalansli hastaliklarda "false positive" sayisinin yuksek olmasindan kaynaklanir. Bu, Base Rate Fallacy (Taban orani yanilgisi) olarak bilinir.

⚠ Base Rate Fallacy - Taban Orani Yanilgisi

Insanlar kosullu olasiliklari degerledirirken genellikle taban oranini (prior) goz ardi eder.

Ornek 2.4'te %99 duyarlilikli bir test bile, nadir bir hastalikta (prevalans %1) sadece %16.7 PPV (Positive Predictive Value) verir!

Neden? Cunku 99.000 saglikli insanin %5'i = 4.950 kisi YANLIS ALARM uretir. Bu sayi, gercek hastalarin (990) neredeyse 5 katidir.

Ders: Bir siniflandirma sisteminin basarimini yorumlarken, siniflarin dagilimini (prior probability) mutlaka goz onune almalisiniz.

2.3 Toplam Olasilik Kurali (Law of Total Probability)

Toplam olasilik kurali, bir olayin olasiligini, farkli kosullar altindaki olasiliklarin agirlikli toplamini alarak hesaplar. Ozellikle olasilik uzayinin parcalara bolunebilecegi durumlarda kullanilir.

Toplam Olasilik Formulu

B1, B2, ..., Bn birbirini dislayan ve ornek uzayini kaplayan olaylar ise:

$$P(A) = P(A|B1)*P(B1) + P(A|B2)*P(B2) + ... + P(A|Bn)*P(Bn)$$

veya kisaca: $P(A) = \Sigma P(A|Bi) * P(Bi)$

Ornek 2.5 - Toplam Olasilik: Fabrika Uretim Hatti

Bir fabrikada 3 makine urun uretiyor:

Makine 1: Uretimin %50'sini yapar, hata orani %3

Makine 2: Uretimin %30'unu yapar, hata orani %5

Makine 3: Uretimin %20'sini yapar, hata orani %8

Soru: Rastgele secilen bir urunun hatali olma olasiligi nedir?

P(Hatali) = P(Hatali|M1)*P(M1) + P(Hatali|M2)*P(M2) + P(Hatali|M3)*P(M3)
P(Hatali) = 0.03 * 0.50 + 0.05 * 0.30 + 0.08 * 0.20
P(Hatali) = 0.015 + 0.015 + 0.016
P(Hatali) = 0.046 = %4.6

Rastgele secilen bir urunun hatali olma olasiligi %4.6'dir.

Ornek 2.6 - Toplam Olasilik: E-posta Filtresi

E-postalarda "Ucretsiz" kelimesinin gecme olasiligini hesaplamak istiyoruz:

P(Spam) = 0.30, P(Normal) = 0.70
P("Ucretsiz" | Spam) = 0.60
P("Ucretsiz" | Normal) = 0.02

P("Ucretsiz") = P("Ucretsiz"|Spam)*P(Spam) + P("Ucretsiz"|Normal)*P(Normal)
P("Ucretsiz") = 0.60 * 0.30 + 0.02 * 0.70
P("Ucretsiz") = 0.18 + 0.014 = 0.194

Tum e-postalarin %19.4'unde "Ucretsiz" kelimesi gecer.
Bu deger, Bayes kuralinda payda olarak kullanilacak!

2.4 Bayes Kurali (Bayes' Theorem)

Bayes kurali, kosullu olasiliklari "ters cevirmeye" yarayan ve oruntu tanima alaninin temel taslarindan biri olan bir formulasyondur. Yeni bilgi (evidence) isiginda bir hipotezin olasiligini guncellememizi saglar.

Bayes Kurali

$$P(A \mid B) = \frac{P(B \mid A) * P(A)}{\quad}$$

P(B)

Burada:

P(A | B): Posterior - B gozlemlendikten sonra A'nin guncellenmis olasiligi

P(A): Prior - A'nin onceki (onsezi) olasiligi

P(B | A): Likelihood - A dogru ise B'nin gozlemlenme olasiligi

P(B): Evidence - B'nin toplam olasiligi (normallestime sabiti)

Bayes Kuralinin Oruntu Tanimada Onemi

Oruntu tanimada siniflandirma problemi aslinda soyledir:

"x ozellik vektoru gozlemlendi. Bu ornit hangi sinifa (w1, w2, ..., wc) aittir?"

Bayes kurali bu soruya dogrudan cevap verir:

$$P(wi \mid x) = \frac{P(x \mid wi) * P(wi)}{P(x)}$$

En yuksek posterior olasiliga sahip sinif secilir: argmax P(wi | x)

Ornek 2.7 - Bayes Kurali: Spam Filtresi (Detayli)

Devam edelim, Ornek 2.6'daki degerleri kullanalim:

P(Spam) = 0.30, P(Normal) = 0.70

P("Ucretsiz" | Spam) = 0.60

P("Ucretsiz" | Normal) = 0.02

P("Ucretsiz") = 0.194 (Ornek 2.6'dan)

Soru: "Ucretsiz" kelimesi gecen bir e-postanin spam olma olasiligi nedir?

P(Spam | "Ucretsiz") = P("Ucretsiz" | Spam) * P(Spam) / P("Ucretsiz")

P(Spam | "Ucretsiz") = 0.60 * 0.30 / 0.194

P(Spam | "Ucretsiz") = 0.18 / 0.194

P(Spam | "Ucretsiz") = 0.928

Dogrulama:

P(Normal | "Ucretsiz") = 0.02 * 0.70 / 0.194 = 0.014 / 0.194 = 0.072

P(Spam|"Ucretsiz") + P(Normal|"Ucretsiz") = 0.928 + 0.072 = 1.00 ✓

Yorum: "Ucretsiz" kelimesi gecen e-postanin spam olma olasiligi %92.8'dir.
Prior %30'dan posterior %92.8'e yukselmistir - tek bir kelime bile buyuk fark yaratir!

✍ Ornek 2.8 - Bayes Kurali: Fabrika Hata Tespiti

Ornek 2.5'teki fabrikada hatali bir urun bulundu.

Soru: Bu hatali urunun Makine 3'ten gelmis olma olasiligi nedir?

Bildigimiz degerler:

P(M1) = 0.50, P(M2) = 0.30, P(M3) = 0.20

P(Hatali|M1) = 0.03, P(Hatali|M2) = 0.05, P(Hatali|M3) = 0.08

P(Hatali) = 0.046 (Ornek 2.5'ten)

Bayes Kurali:

P(M3 | Hatali) = P(Hatali | M3) * P(M3) / P(Hatali)

P(M3 | Hatali) = 0.08 * 0.20 / 0.046

P(M3 | Hatali) = 0.016 / 0.046 = 0.348

Dogrulama - Diger makineler:

P(M1 | Hatali) = 0.03 * 0.50 / 0.046 = 0.015/0.046 = 0.326

P(M2 | Hatali) = 0.05 * 0.30 / 0.046 = 0.015/0.046 = 0.326

Toplam: 0.326 + 0.326 + 0.348 = 1.00 ✓

Yorum: M3 uretimin sadece %20'sini yapsa da, hatali urunun M3'ten gelme olasiligi %34.8.
Bunun nedeni M3'un hata oraninin (%8) diger makinelere gore yuksek olmasi.

✍ Ornek 2.9 - Bayes Kurali: Tibbi Teshis (Ornek 2.4 Devami)

Ornek 2.4'teki tibbi test senaryosunu Bayes kurali ile cozelim:

P(Hasta) = 0.01, P(Saglikli) = 0.99
P(Test+ | Hasta) = 0.99 (Sensitivity)
P(Test+ | Saglikli) = 0.05 (1 - Specificity)

Adim 1 - Evidence hesapla:
P(Test+) = P(Test+|Hasta)*P(Hasta) + P(Test+|Saglikli)*P(Saglikli)
P(Test+) = 0.99 * 0.01 + 0.05 * 0.99
P(Test+) = 0.0099 + 0.0495 = 0.0594

Adim 2 - Posterior hesapla:
P(Hasta | Test+) = P(Test+|Hasta) * P(Hasta) / P(Test+)
P(Hasta | Test+) = 0.99 * 0.01 / 0.0594
P(Hasta | Test+) = 0.0099 / 0.0594 = 0.1667 = %16.67

Ikinci test yapilirsa? (Simdi prior guncellenir!)
Yeni P(Hasta) = 0.1667 (ilk testten gelen posterior)
Yeni P(Saglikli) = 0.8333

P(Test+) = 0.99 * 0.1667 + 0.05 * 0.8333 = 0.1650 + 0.0417 = 0.2067
P(Hasta | 2.Test+) = 0.99 * 0.1667 / 0.2067 = 0.1650 / 0.2067 = 0.798

Sonuc: Ikinci test de pozitif cikinca olasilik %79.8'e yukselir!
Bu, Bayesian guncellemenin gucunu gosterir: her yeni kanit posterior'u gunceller.

2.5 Prior, Likelihood ve Posterior Kavramlari

Bayes kuralindaki her terimin oruntu tanimada belirli bir anlami vardir. Bu kavramlari anlamak, siniflandirma sistemlerinin tasariminda kritik oneme sahiptir.

Terim	Sembol	Anlami	Nereden Gelir?
Prior	P(wi)	Sinifin onceki olasiligi, hicbir gozlem yapilmadan	Egitim verisindeki sinif dagilimi veya uzman bilgisi

Likelihood	P(x | wi)	wi sinifina ait bir verinin x degerini alma olasiligi	Egitim verisinden istatistiksel modelleme
Evidence	P(x)	x'in gozlemlenme olasiligi (normallestime sabiti)	Toplam olasilik kurali ile hesaplanir
Posterior	P(wi | x)	x gozlemlendikten sonra wi sinifinin guncellenmis olasiligi	Bayes kurali ile hesaplanir

✍ Ornek 2.10 - Prior, Likelihood, Posterior: Meyve Siniflandirma

Bir kutuda elmalar ve portakallar var. Meyvenin rengine bakarak siniflandirmak istiyoruz.

Prior (Onceki Bilgi):

Kutuda 60 elma, 40 portakal var

P(Elma) = 0.60, P(Portakal) = 0.40

Likelihood (Ozellik Olasiliklari):

Kirmizi renk olasiligi:

P(Kirmizi | Elma) = 0.80 (elmalarin %80'i kirmizi)

P(Kirmizi | Portakal) = 0.05 (portakallarin %5'i kirmizimsi)

Evidence:

P(Kirmizi) = 0.80*0.60 + 0.05*0.40 = 0.48 + 0.02 = 0.50

Posterior (Gozlem Sonrasi):

P(Elma | Kirmizi) = 0.80 * 0.60 / 0.50 = 0.48/0.50 = 0.96

P(Portakal | Kirmizi) = 0.05 * 0.40 / 0.50 = 0.02/0.50 = 0.04

Karar: Kirmizi meyve %96 olasilikla ELMA'dir.

Ek soru: Yesil bir meyve gelirse?

P(Yesil | Elma) = 0.15, P(Yesil | Portakal) = 0.00

P(Yesil) = 0.15*0.60 + 0.00*0.40 = 0.09

P(Elma | Yesil) = 0.15 * 0.60 / 0.09 = 0.09/0.09 = 1.00

Yesil meyve kesinlikle elmadir (portakal yesil olamaz).

Ornek 2.11 - Prior'un Etkisi: Ayni Likelihood, Farkli Prior

Ayni likelihood degerlerinin farkli prior'larla nasil farkli sonuclar ureteceigini gorelim:

Likelihood (sabit):

P(x | w1) = 0.3, P(x | w2) = 0.1

Senaryo A: Dengeli prior

P(w1) = 0.50, P(w2) = 0.50

P(x) = 0.3*0.50 + 0.1*0.50 = 0.20

P(w1|x) = 0.3*0.50/0.20 = 0.75

P(w2|x) = 0.1*0.50/0.20 = 0.25

Karar: w1 (%75)

Senaryo B: w2 baskin prior

P(w1) = 0.10, P(w2) = 0.90

P(x) = 0.3*0.10 + 0.1*0.90 = 0.03 + 0.09 = 0.12

P(w1|x) = 0.3*0.10/0.12 = 0.25

P(w2|x) = 0.1*0.90/0.12 = 0.75

Karar: w2 (%75) --> TERS SONUC!

Ders: Ayni likelihood bile, farkli prior ile tamamen farkli kararlara yol acabilir! Prior secimi kritiktir.

2.6 Bagimsizlik ve Kosullu Bagimsizlik

Iki olay birbirinden bagimsizsa, birinin gerceklesmesi digerinin olasiligini etkilemez. Oruntu tanimada ozellik bagimsizligi onemli bir varsayimdir.

Bagimsizlik Kosulu

A ve B bagimsiz ise:

$P(A \cap B) = P(A) * P(B)$

$P(A \mid B) = P(A)$

$P(B \mid A) = P(B)$

Kosullu bagimsizlik (C bilindiginde A ve B bagimsiz):

$P(A \cap B \mid C) = P(A \mid C) * P(B \mid C)$

✍ Ornek 2.12 - Bagimsizlik Testi

200 ogrenci uzerinde yapilan bir arastirma:

	Geciyor	Kaliyor	Toplam
Erkek	60	40	100
Kadin	60	40	100
Toplam	120	80	200

Cinsiyet ve basari bagimsiz mi?

P(Geciyor) = 120/200 = 0.60

P(Geciyor | Erkek) = 60/100 = 0.60

P(Geciyor | Kadin) = 60/100 = 0.60

P(Geciyor | Erkek) = P(Geciyor) = 0.60 --> BAGIMSIZ ✓

Simdi farkli bir senaryo:

	Geciyor	Kaliyor	Toplam
Erkek	80	20	100
Kadin	40	60	100
Toplam	120	80	200

P(Geciyor) = 120/200 = 0.60

P(Geciyor | Erkek) = 80/100 = 0.80

P(Geciyor | Kadin) = 40/100 = 0.40

P(Geciyor | Erkek) ≠ P(Geciyor) --> BAGIMLI ✗

✍ Ornek 2.13 - Kosullu Bagimsizlik: Spam Filtresi

Bir e-postada 2 kelime var: "ucretsiz" ve "kazandiniz"

Normal konusmada bu kelimeler bagimlidir (ikisi de pazarlama diline aittir).

Ancak Naive Bayes varsayimi ile SINIF BILINDIGNDE bagimsiz kabul edilir:

P("ucretsiz" VE "kazandiniz" | Spam) = P("ucretsiz" | Spam) * P("kazandiniz" | Spam)

P("ucretsiz" | Spam) = 0.60
P("kazandiniz" | Spam) = 0.45
P(iki kelime | Spam) = 0.60 * 0.45 = 0.27

P("ucretsiz" | Normal) = 0.02
P("kazandiniz" | Normal) = 0.01
P(iki kelime | Normal) = 0.02 * 0.01 = 0.0002

P(Spam) = 0.30, P(Normal) = 0.70
P(Spam | iki kelime) = (0.27 * 0.30) / (0.27*0.30 + 0.0002*0.70)
= 0.081 / (0.081 + 0.00014)
= 0.081 / 0.08114 = 0.9983

Sonuc: %99.83 olasilikla SPAM! Iki kelimenin birlikte bulunmasi olasiligi cok artirmistir.

2.7 Olasilik Dagilimlari (Temel)

Oruntu tanimada ozelliklerin dagilimini modellemek icin olasilik dagilimlari kullanilir. En sik kullanilan dagilimlar asagida aciklanmistir.

2.7.1 Kesikli Dagilimlar

Bernoulli Dagilimi: Iki sonuclu deneyler icin kullanilir (basari/basarisizlik, spam/normal). P(X=1) = p, P(X=0) = 1-p.

Binom Dagilimi: n bagimsiz Bernoulli deneyinde k basari elde etme olasiligini verir. P(X=k) = C(n,k) * p^k * (1-p)^(n-k).

Ornek 2.14 - Binom Dagilimi: Kalite Kontrol

Bir uretim hattinda hata orani p = 0.05. 20 urun secilirse:

Soru: Tam olarak 2 hatali urun cikma olasiligi nedir?

n = 20, k = 2, p = 0.05

P(X=2) = C(20,2) * 0.05^2 * 0.95^18

C(20,2) = 20! / (2! * 18!) = 190

0.05^2 = 0.0025

0.95^18 = 0.3972

P(X=2) = 190 * 0.0025 * 0.3972 = 0.1887 = %18.87

Soru: Hic hatali urun cikmama olasiligi nedir?

P(X=0) = C(20,0) * 0.05^0 * 0.95^20 = 1 * 1 * 0.3585 = 0.3585 = %35.85

2.7.2 Surekli Dagilimlar - Normal (Gauss) Dagilimi

Normal dagilim, oruntu tanimada en cok kullanilan surekli dagilimdir. Bircok dogal olay (boy, kilo, olcum hatalari) yaklasik olarak normal dagilim gosterir.

Normal Dagilim Formulu

$$f(x) = \frac{1}{\sigma * \sqrt{(2\pi)}} * \exp\left(- \frac{(x - \mu)^2}{2\sigma^2} \right)$$

μ (mu): Ortalama (dagillmin merkezi)

σ (sigma): Standart sapma (dagillmin genisligi)

σ²: Varyans

Ornek 2.15 - Normal Dagilim: Boy Siniflandirma

Erkek ve kadin boylarinin normal dagildigini varsayalim:

Erkek: μ1 = 175 cm, σ1 = 7 cm

Kadin: μ2 = 162 cm, σ2 = 6 cm

P(Erkek) = 0.50, P(Kadin) = 0.50

Soru: Boyu 170 cm olan birinin cinsiyetini tahmin edin.

Adim 1 - Likelihood hesapla:

$f(170 \mid Erkek) = (1/(7*\sqrt{(2\pi)})) * \exp(-(170-175)^2/(2*49))$

$= 0.05696 * \exp(-25/98)$

$= 0.05696 * \exp(-0.2551)$

$= 0.05696 * 0.7747 = 0.04413$

$f(170 \mid Kadin) = (1/(6*\sqrt{(2\pi)})) * \exp(-(170-162)^2/(2*36))$

$= 0.06649 * \exp(-64/72)$

$= 0.06649 * \exp(-0.8889)$

$= 0.06649 * 0.4111 = 0.02733$

Adim 2 - Evidence:

$f(170) = 0.04413 * 0.50 + 0.02733 * 0.50 = 0.02207 + 0.01367 = 0.03573$

Adim 3 - Posterior:

$P(Erkek \mid 170) = 0.04413 * 0.50 / 0.03573 = 0.02207/0.03573 = 0.6175$

$P(Kadin \mid 170) = 0.02733 * 0.50 / 0.03573 = 0.01367/0.03573 = 0.3825$

Karar: 170 cm boy, %61.7 olasilikla ERKEK. Ama belirsizlik yuksek!

Eger boy 185 cm olsaydi:

$f(185|Erkek) = 0.02988$, $f(185|Kadin) = 0.00017$

$P(Erkek|185) = 0.02988*0.50 / (0.02988*0.50 + 0.00017*0.50) = 0.994$

185 cm boy %99.4 olasilikla erkek - cok daha kesin!

2.8 Maksimum Olabilirlik Tahmini (Maximum Likelihood Estimation - MLE)

MLE, bir olasilik dagiliminin parametrelerini (ornegin ortalama ve varyans), gozlemlenen verilere en iyi uyacak sekilde tahmin etme yontemidir.

MLE Prensibi

Verilen veri kumesi $D = \{x1, x2, ..., xn\}$ icin:

$L(\theta) = P(D \mid \theta) = P(x1|\theta) * P(x2|\theta) * ... * P(xn|\theta)$ (bagimsizlik varsayimi)

$\theta_MLE = \text{argmax } L(\theta)$

Pratikte log-likelihood kullanilir:

$\ln L(\theta) = \Sigma \ln P(xi|\theta)$ --> Toplama islemine doner, hesaplamasi kolaydir.

✍ Ornek 2.16 - MLE: Normal Dagilim Parametreleri

5 ogrencinin sinav notlari: {72, 85, 68, 91, 79}

Bu verilerin normal dagilimdan geldigini varsayiyoruz. μ ve σ^2 nedir?

MLE ile μ tahmini:

$\mu_MLE = (1/n) * \Sigma xi = (72 + 85 + 68 + 91 + 79) / 5$

$\mu_MLE = 395 / 5 = 79.0$

MLE ile σ^2 tahmini:

$\sigma^2_MLE = (1/n) * \Sigma (xi - \mu)^2$

$= (1/5) * [(72-79)^2 + (85-79)^2 + (68-79)^2 + (91-79)^2 + (79-79)^2]$

$= (1/5) * [49 + 36 + 121 + 144 + 0]$

$= (1/5) * 350 = 70.0$

$\sigma_MLE = \sqrt{70} = 8.37$

Sonuc: Notlar N(79.0, 70.0) dagilimina uyar. $\mu=79$, $\sigma=8.37$

✍ Ornek 2.17 - MLE: Iki Sinifli Problem

Bir meyve siniflandirma probleminde boy (cm) olculeri:

Elma boylari: {7.2, 7.5, 6.8, 7.0, 7.8, 7.3}

Portakal boylari: {8.5, 9.0, 8.2, 8.8, 9.5, 8.7}

Elma icin MLE:

$\mu_elma = (7.2+7.5+6.8+7.0+7.8+7.3) / 6 = 43.6/6 = 7.267$

$\sigma^2_elma = [(7.2-7.267)^2 + ... + (7.3-7.267)^2] / 6$

$= [0.0045+0.0544+0.2178+0.0711+0.2844+0.0011] / 6$

$= 0.6333 / 6 = 0.1056$

σ_elma = 0.3249

Portakal icin MLE:

μ_portakal = (8.5+9.0+8.2+8.8+9.5+8.7) / 6 = 52.7/6 = 8.783

σ^2_portakal = 0.1997, σ_portakal = 0.4469

Yeni meyve boyu 8.0 cm. Sinifini belirle:

f(8.0|Elma) = N(8.0; 7.267, 0.1056) = 0.0254

f(8.0|Portakal) = N(8.0; 8.783, 0.1997) = 0.1268

P(Elma)=0.5, P(Portakal)=0.5 varsayimiyla:

P(Elma|8.0) = 0.0254*0.5 / (0.0254*0.5+0.1268*0.5) = 0.0127/0.0761 = 0.167

P(Portakal|8.0) = 0.833

Karar: %83.3 olasilikla PORTAKAL.

2.9 Maksimum A Posteriori (MAP) Tahmini

MAP tahmini, MLE'ye ek olarak parametre hakkindaki onceki bilgiyi (prior) de hesaba katar. MLE sadece likelihood'i maksimize ederken, MAP posterior'u maksimize eder.

MLE vs MAP Karsilastirmasi

MLE: θ_MLE = argmax P(D | θ)

MAP: θ_MAP = argmax P(θ | D) = argmax P(D | θ) * P(θ)

Fark: MAP, prior P(θ) terimini de icerir.

Eger prior uniform (duz) ise, MAP = MLE olur.

Veri sayisi arttikca MAP, MLE'ye yakinsar (prior'un etkisi azalir).

Ornek 2.18 - MLE vs MAP: Madeni Para

Bir madeni para 10 kez atildi, 8 yazi geldi.

MLE Tahmini:

p_MLE = 8/10 = 0.80 ("para %80 yazi gelir" diye tahmin eder)

MAP Tahmini (prior: paranin adil olduguna inaniyoruz):

Prior: Beta(α=10, β=10) dagilimi (p=0.5 civari yogun)

Gozlem: 8 yazi, 2 tura

Posterior: Beta(α+8, β+2) = Beta(18, 12)

p_MAP = (α-1)/(α+β-2) = 17/28 = 0.607

Yorum:

MLE: 0.80 (sadece veriye bakiyor)

MAP: 0.607 (veriyi ve onceki bilgiyi dengeliyor)

MAP daha makul cunku 10 atisla paranin %80 hileli oldugunu iddia etmek abart.

Eger 1000 atis yapilsa ve 800 yazi gelseydi:

p_MLE = 0.80, p_MAP = 807/1018 = 0.793

Cok veri ile MAP, MLE'ye yakinsar!

2.10 Bayes Minimum Hata Orani Siniflandirmasi

Bayes siniflandirici, siniflandirma hatasini minimize eden optimal siniflandiricidir. Karar kurali basittir: her zaman en yuksek posterior olasiliga sahip sinifi sec.

Bayes Karar Kurali

x'i wi sinifina ata eger: P(wi | x) > P(wj | x) tum j ≠ i icin

Esdeger olarak (P(x) tum siniflar icin ayni oldugu icin):

x'i wi sinifina ata eger: P(x | wi) * P(wi) > P(x | wj) * P(wj)

Iki sinifli durumda, sinir (boundary):

P(x | w1) * P(w1) = P(x | w2) * P(w2)

veya: P(x|w1)/P(x|w2) = P(w2)/P(w1) (likelihood ratio = prior ratio)

Ornek 2.19 - Bayes Karar Siniri: Tek Ozellik

Iki sinifli bir problem. Ozellik x surekli ve normal dagilimli:

w1: μ1 = 3, σ² = 1, P(w1) = 0.60

w2: $\mu_2 = 7$, $\sigma^2 = 1$, $P(w_2) = 0.40$

Esit varyansli normal dagilimlar icin karar siniri:

$x^* = (\mu_1 + \mu_2)/2 + [\sigma^2/(\mu_2-\mu_1)] * \ln[P(w_2)/P(w_1)]$

$x^* = (3+7)/2 + [1/(7-3)] * \ln(0.40/0.60)$

$x^* = 5.0 + 0.25 * \ln(0.6667)$

$x^* = 5.0 + 0.25 * (-0.4055)$

$x^* = 5.0 - 0.1014 = 4.899$

Karar kurali:

Eger $x < 4.899$ --> w1

Eger $x > 4.899$ --> w2

Not: Prior'lar esit olsaydi (0.50/0.50), sinir tam x=5.0 olurdu.

$P(w_1)=0.60 > P(w_2)$ oldugu icin sinir w2 yonune kaydi (w1 lehine).

✍ Ornek 2.20 - Bayes Hata Orani Hesaplama

Ornek 2.19'daki siniflandirici icin hata oranini hesaplayalim:

Karar siniri: $x^* = 4.899$

Hata 1: w1'e ait olup w2 diye siniflandirilan ($x > 4.899$ olan w1 ornekleri)

$P(\text{hata1}) = P(x > 4.899 \mid w_1) * P(w_1)$

$z = (4.899 - 3) / 1 = 1.899$

$P(x > 4.899 \mid w_1) = 1 - \Phi(1.899) = 1 - 0.9713 = 0.0287$

$P(\text{hata1}) = 0.0287 * 0.60 = 0.0172$

Hata 2: w2'ye ait olup w1 diye siniflandirilan ($x < 4.899$ olan w2 ornekleri)

$P(\text{hata2}) = P(x < 4.899 \mid w_2) * P(w_2)$

$z = (4.899 - 7) / 1 = -2.101$

$P(x < 4.899 \mid w_2) = \Phi(-2.101) = 0.0178$

$P(\text{hata2}) = 0.0178 * 0.40 = 0.0071$

Toplam Bayes Hata Orani: P(hata) = 0.0172 + 0.0071 = 0.0243 = %2.43

Bu, elde edilebilecek en dusuk hata orani. Hicbir siniflandirici bundan daha iyi yapamaz!

2.11 Bolum Ozeti

Kavram	Ozet
Olasilik	0 ile 1 arasinda, bir olayin gerceklesme ihtimali. Aksiyomlar: non-negatiflik, toplam=1, toplamsallik
Kosullu Olasilik	P(A|B) = P(A∩B)/P(B). Bir olay bilindiginde diger olayin guncellenmis olasiligi
Bayes Kurali	P(A|B) = P(B|A)*P(A)/P(B). Posterior = Likelihood * Prior / Evidence
Prior	P(wi) - Gozlem oncesi sinif olasiligi
Likelihood	P(x|wi) - Sinif bilindiginde verinin olasiligi
Posterior	P(wi|x) - Veri gozlemlendikten sonra sinif olasiligi
Toplam Olasilik	P(B) = Σ P(B|Ai)*P(Ai) - Tum kosullar uzerinden toplam
Bagimsizlik	P(A∩B) = P(A)*P(B) ise olaylar bagimsizdir
MLE	Likelihood'u maksimize eden parametre tahmini
MAP	Posterior'u maksimize eden parametre tahmini (MLE + prior)
Bayes Siniflandirici	En yuksek posterior'lu sinifi secer, minimum hata oranini garanti eder

2.12 Calisma Sorulari

1. Bir kutuda 5 kirmizi, 3 mavi, 2 yesil top var. Rastgele 1 top cekilirse: (a) Kirmizi gelme olasiligi nedir? (b) Kirmizi VEYA mavi gelme olasiligi nedir? (c) Yesil gelmeme olasiligi nedir?
2. Bir hastalik prevalansi %2. Testin sensitivity=%95, specificity=%90. Testi pozitif cikan birinin gercekten hasta olma olasiligini Bayes kurali ile hesaplayiniz.
3. Bir siniflandirma probleminde P(w1)=0.70, P(w2)=0.30, P(x|w1)=0.4, P(x|w2)=0.8 ise x gozlemlenen bir ornegi hangi sinifa atarsiniz? Posterior olasiliklari hesaplayiniz.
4. Bir e-postada "kazandiniz" ve "tiklayiniz" kelimeleri geciyor. P(Spam)=0.25, P("kazandiniz"|Spam)=0.70, P("kazandiniz"|Normal)=0.01, P("tiklayiniz"|Spam)=0.50, P("tiklayiniz"|Normal)=0.03. Naive Bayes varsayimi ile spam olasiligini hesaplayiniz.

5. 3 fabrika ayni urunu uretiyor. Fabrika A uretimin %40'ini (%2 hata), B %35'ini (%3 hata), C %25'ini (%5 hata) yapiyour. (a) Rastgele urunun hatali olma olasiligi? (b) Hatali urunun C'den gelme olasiligi?
6. Su veriler icin MLE ile normal dagilim parametrelerini (μ, σ^2) hesaplayiniz: {55, 62, 58, 71, 64, 60}. Sonra x=66 degerinin bu dagilima gore olasilik yogunlugunu bulunuz.
7. MLE ve MAP arasindaki farki aciklayiniz. Az veri oldugunda hangisi daha guvenilir sonuc verir? Neden?
8. Base Rate Fallacy nedir? Nadir bir hastalik icin %99 duyarlilikli bir test neden gercekte dusuk PPV verebilir? Sayisal ornekle gosteriniz.
9. Iki sinif icin Bayes karar sinirini turetiniz: w1 ~ N(4, 2), w2 ~ N(8, 2), P(w1)=P(w2)=0.5. Karar siniri nerededir? P(w1)=0.7 olursa sinir nasil degisir?
10. Bir madeni para 20 kez atilip 15 yazi geldiyse, MLE ile yazi olasiligiini tahmin ediniz. Beta(5,5) prior ile MAP tahminini de yapiniz ve iki sonucu karsilastiriniz.